📊 机器学习 复习笔记

> 一句话说清机器学习：**让计算机从数据中自动学习规律，然后用学到的规律做预测或决策。** 📈 → 🧠 → 🎯

📌 知识地图（先看整体框架）

```
                    机器学习
                       |
        ┌──────────────┼──────────────┐
        |              |              |
    监督学习        无监督学习       强化学习
   （有标签）       （无标签）       （奖励信号）
        |              |              |
    ┌───┴───┐      ┌───┴───┐          |
    |       |      |       |          |
  分类    回归    聚类    降维      Q-Learning等
（离散值）（连续值）（K-Means）（PCA）
        |
    ┌───┴──────────┐
    |              |
  弱监督学习      迁移学习
    ┌┼┐            |
  不完全 不确切 不准  预训练+微调
```

一、🧠 机器学习基础概念

知识点 1：什么是机器学习？

定义：计算机利用**经验**（数据）来改善**性能**指标的过程。

输入：数据（经验）
过程：学习算法从数据中发现规律
输出：一个模型（可以用来做预测）

一个核心公式：

学习算法 + 训练数据 → 模型 → 预测新数据

知识点 2：基本术语

术语	英文	含义	比喻 🌰
样本	Sample / Instance	一条数据记录	一个学生的信息
特征	Feature	样本的某个属性	年龄、身高、成绩
特征向量	Feature Vector	所有特征组成的向量	(年龄, 身高, 成绩)
标签	Label	我们要预测的目标值	是否被录取 ✅ ❌
数据集	Data Set	所有样本的集合	全班学生的数据
训练集	Training Set	用来训练模型的数据	过去学生的数据
测试集	Test Set	用来评估模型的数据	新学生的数据

知识点 3：几个重要的假设

假设	含义
独立同分布（IID） 📊	训练数据和测试数据来自同一分布，且相互独立
数据充分性 ✅	数据量要足够大，才能学到可靠规律

二、📐 机器学习的核心框架

知识点 4：模型、假设空间与学习

模型 = 从输入到输出的映射函数：

```
线性回归：y = wx + b              ← 参数 w 和 b 控制模型行为
神经网络：y = σ(W·x + b)          ← 参数 W 和 b
决策树：一系列 if-then 规则        ← 树结构参数
```

假设空间（Hypothesis Space）：所有可能的模型组成的集合。

```
假设空间 H = { f(x; θ) | θ ∈ Θ }

θ 是模型参数，Θ 是所有可能的参数取值
H 中包含了所有可能的学习结果
```

> 💡 机器学习 = 在假设空间中搜索一个"最好"的模型，使其在训练数据上表现最好。

知识点 5：损失函数与风险

损失函数 L(y, f(x))：衡量模型预测值和真实值之间的差距。

任务	常用损失函数
回归 📈	均方误差 MSE：$L(y, \hat{y}) = (y - \hat{y})^2$
分类 🏷️	交叉熵（Cross-Entropy）、0-1 损失

三种风险最小化：

```
① 期望风险（Expected Risk）—— 理论上最优，但算不了
   R(θ) = ∫ L(y, f(x,θ)) · p(x,y) dx dy

② 经验风险（Empirical Risk）—— 用训练数据近似
   R_emp(θ) = 1/N · Σ L(yᵢ, f(xᵢ,θ))

③ 结构风险（Structural Risk）—— 加正则项防过拟合
   R_srm(θ) = R_emp(θ) + λ·Ω(θ)
```

知识点 6：过拟合 vs 欠拟合

```
欠拟合（Underfitting）          过拟合（Overfitting）
      😅                              😰

┌──────────────────┐        ┌──────────────────┐
│  模型太简单       │        │  模型太复杂       │
│  训练集也学不好   │        │  训练集完美但     │
│  测试集更差       │        │  测试集很差       │
└──────────────────┘        └──────────────────┘

        👍 刚刚好（Good Fit）
┌──────────────────┐
│  模型复杂度适中   │
│  训练集和测试集   │
│  表现都很好       │
└──────────────────┘
```

训练过程示意图：

```
误差
↑
│      训练误差
│     ┌──┐
│    ┌┘  └──┐              测试误差
│   ┌┘      └──┐        ┌──┐
│  ┌┘          └──┐    ┌┘  └──┐
│  ┌┘              └────┘      └──────→ 模型复杂度
│←---- 欠拟合 ---→←--- 过拟合 ---→
```

问题	原因	解决方法
欠拟合 😅	模型太简单 / 特征不够	增加模型复杂度、增加特征
过拟合 😰	模型太复杂 / 数据太少	正则化、减少特征、增加数据

知识点 7：机器学习的典型流程

① 收集数据 📝
② 数据预处理（清洗、归一化、特征工程） 🧹
③ 划分训练集 / 验证集 / 测试集 ✂️
④ 选择模型（线性回归、SVM、神经网络等）
⑤ 设置超参数（学习率、正则化系数等） ⚙️
⑥ 在训练集上训练模型 🏋️
⑦ 在验证集上调优 🔧
⑧ 在测试集上评估 🧪
⑨ 部署到实际应用 🚀

三、🏷️ 监督学习（Supervised Learning）

知识点 8：什么是监督学习?

输入：带标签的训练数据 $\{(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)\}$
任务：学习从 x 到 y 的映射 $f: X \to Y$

```
                ┌── 分类（Classification）
监督学习 ───────┤                y 是离散的（猫/狗、正/负）
                │
                └── 回归（Regression）
                           y 是连续的（房价、温度）
```

常见算法：

算法	类型	一句话说清
线性回归 📈	回归	$y = wx + b$，找到最拟合数据的直线
逻辑回归 📉	分类	用 Sigmoid 函数把输出变成 [0,1] 的**概率**
决策树 🌳	分类/回归	一堆 if-then 规则组成的树
SVM 🏋️	分类	找到两个类别之间最宽的"间隔"
朴素贝叶斯 🧮	分类	用概率公式 $P(y\|x) \propto P(x\|y)P(y)$

四、🔍 无监督学习（Unsupervised Learning）

知识点 9：什么是无监督学习?

输入：只有数据 x_i，没有标签 y_i
任务：发现数据中隐藏的结构或模式

```
                  ┌── 聚类（Clustering）— 物以类聚
无监督学习 ───────┤
                  └── 降维（Dimensionality Reduction）— 简化数据
```

知识点 10：K-Means 聚类

核心思想：把数据分成 K 个簇，让**同一簇内的点尽量近，不同簇的点尽量远**。

K-Means 的步骤：

```
① 随机选 K 个点作为初始"中心"
② 每个点分给离它最近的中心
③ 更新每个簇的中心（取簇内点的平均值）
④ 重复 ②③ 直到中心不再变化
```

```
初始状态          第1轮          第3轮          收敛
  · · ·          · · ·          · · ·          · · ·
  · · ·   →      · · ·   →      · · ·   →      · · ·
 ·⊕· ··  ⊕·     ·⊕· ··  ⊕·     ·⊕· ··  ⊕·     ·⊕· ··  ⊕·
  · · ·          · · ·          · · ·          · · ·
  · · ·          · · ·          · · ·          · · ·
⊕ = 簇中心      · = 数据点      颜色 = 隶属簇
```

常见降维方法：**PCA**（主成分分析）📉

五、🔄 其他学习范式

知识点 11：弱监督学习（Weakly Supervised Learning）

定义：使用不完美监督信号的学习方法。包含三种情况：

类型	说明	例子
不完全监督 🕳️	只有部分数据有标签	100 万张图，只有 1000 张有标签
不确切监督 ❓	标签不够精确	一张图上有猫和狗，但只标了"动物"
不准确监督 ⚠️	标签可能有错误	标注人员标错了类别

知识点 12：迁移学习（Transfer Learning）🎁

核心思想：把在某个任务上学到的知识，应用到另一个相关任务上。

```
传统学习：对每个新任务都要从头学起 ❌
        任务A → 模型A      任务B → 从头训练模型B

迁移学习：在任务A上学到知识，迁移到任务B ✅
        任务A → 基础模型 → 微调 → 任务B的模型
```

> 💡 **例子**：用 ImageNet（1000 类图片分类）训练好的 CNN，拿去识别医学影像（只需要少量医学图片微调）。

知识点 13：更多学习范式一览

范式	一句话说清
自监督学习 🪞	从数据本身构造监督信号（如 BERT 预测被遮住的词）
度量学习 📏	学一个距离函数，让同类样本距离近，异类远
对比学习 🔁	让相似样本的表示靠近，不相似的远离
对抗学习 🎭	生成对抗样本攻击模型，再让模型学会抵抗
元学习 🧠	"学会学习"——在新任务上快速适应

六、📚 学习理论要点

知识点 14：没有免费午餐定理（No Free Lunch Theorem）🍽️

> **核心结论**：没有一种算法在所有问题上都是最好的。

```
算法A在问题集P₁上表现好
算法B在问题集P₂上表现好

如果对所有可能的问题求平均，所有算法的期望性能是一样的。
```

实际意义：选择算法需要根据**具体问题**判断，不能盲目迷信某种算法。

知识点 15：丑小鸭定理（Ugly Duckling Theorem）🦢

> **核心结论**：没有绝对客观的分类标准，分类依赖于我们的**主观偏好**。

```
丑小鸭和白天鹅的"差异"，取决于你用什么标准来衡量：
- 按外形分：丑小鸭 ≠ 白天鹅
- 按基因分：丑小鸭 = 白天鹅（都是天鹅科）
```

知识点 16：奥卡姆剃刀（Occam's Razor）🪒

Entities should not be multiplied unnecessarily. —— William of Occam

> **核心结论**：在效果相同时，**选择最简单的那个模型**。

```
如果有两个模型在训练集上表现一样好：
  模型A：3 个参数（简单） 👍
  模型B：30 个参数（复杂）

奥卡姆剃刀说：选模型A！更简单的模型更可能泛化到新数据。
```

知识点 17：归纳偏置（Inductive Bias）🎯

> **核心问题**：数据是有限的，但可能的模型是无限的。如何选择？

归纳偏置 = 学习算法在假设空间中做选择时的**先验偏好**。

算法	归纳偏置
线性回归 📈	假设 x 和 y 的关系是线性的
CNN 🧠	假设图像特征具有局部性和平移不变性
RNN 🔄	假设数据具有时序依赖
决策树 🌳	倾向于选择较短的树

> 💡 **没有归纳偏置就无法学习**——数据本身不足以确定唯一模型，必须加上先验假设。

📝 自测题

基础概念：

1. 什么是机器学习？给出你自己的定义和例子。
2. 训练集、验证集、测试集各有什么作用？
3. 过拟合和欠拟合的区别是什么？各怎么解决？

监督学习：
4. 分类和回归的区别是什么？各举两个例子。
5. 什么是独立同分布（IID）假设？如果这个假设不成立会怎样？

无监督学习：
6. K-Means 的核心思想是什么？简述其步骤。

学习理论：
7. 没有免费午餐定理告诉我们什么？选算法时应该怎么思考？
8. 奥卡姆剃刀在机器学习中的应用是什么？
9. 什么是归纳偏置？CNN 的归纳偏置是什么？

综合：
10. 比较传统学习（从头训练）和迁移学习的关键区别。

📖 推荐阅读

- Mitchell, Machine Learning, 1997（经典教材）

- 周志华, 机器学习（西瓜书）🍉
- Bishop, Pattern Recognition and Machine Learning, 2006
- Goodfellow et al., Deep Learning, 2016（花书）
- Zhou, A Brief Introduction to Weakly Supervised Learning, NSR 2018