🤖 行为学派（二）：强化学习 复习笔记

> 一句话说清强化学习：**智能体（Agent）在环境（Environment）中试错，做动作（Action），获得奖励（Reward），学会让累计奖励最大化的策略。** 🎮 → 🧠 → 🏆

📌 知识地图（先看整体框架）

```
🧠 强化学习 (Reinforcement Learning)
│
├── 🎯 核心概念
│      ├── Agent（智能体）— 做决策的"你"
│      ├── Environment（环境）— 你所在的"世界"
│      ├── Action（动作）— 你做的每一步操作
│      ├── State（状态）— 当前世界的情况
│      ├── Reward（奖励）— 你做对了/做错了的反馈
│      └── Policy（策略）— 你在每个状态下该做什么
│
├── 📐 数学框架
│      ├── MDP（马尔可夫决策过程）
│      ├── Value Function（价值函数）
│      └── Bellman Equation（贝尔曼方程）
│
└── 🚀 重要里程碑
       ├── DQN（玩 Atari 游戏）
       ├── AlphaGo / AlphaZero（下围棋）
       └── OpenAI Five / ChatGPT（大规模 RL）
```

一、🎯 强化学习核心概念

知识点 1：强化学习 vs 其他学习范式

学习方式	比喻 🎭	数据来源	反馈
监督学习 📚	老师教学生	带标签的数据集	即时（每道题都有正确答案）
无监督学习 🔍	自己整理房间	无标签数据	无反馈
强化学习 🎮	玩游戏自己摸索	与环境的交互	**延迟**（可能要很多步才有奖励）

知识点 2：RL 的基本要素（六个核心概念 ⭐）

```
🎮 Agent（智能体）
  │
  │  Action（动作）a_t
  ▼
┌──────────────────┐
│  Environment     │
│   （环境）        │
└──────────────────┘
  │
  │  ① State（状态）s_{t+1}
  │  ② Reward（奖励）r_{t+1}
  ▼
🎮 Agent（更新策略）
```

概念	符号	比喻 🏫	定义
Agent 🤖	-	学生	做决策的智能体
Environment 🌍	-	学校/考场	Agent 交互的外部世界
State 📊	s_t	你当前的知识水平	环境的当前状况
Action 🎮	a_t	你决定学哪科	Agent 做出的操作
Reward 🏆	r_t	考试成绩（分数）	环境给 Agent 的反馈信号
Policy 📋	π(a|s)	你的学习方法论	在状态 s 下做什么动作的策略

知识点 3：RL 的学习循环

```
智能体观察环境 → 根据策略选择动作 → 环境改变并返回新状态+奖励 → 智能体更新策略

Repeat!

目标是：找到最优策略 π*，使累计奖励（Return）最大！🏆
```

二、🧠 强化学习的生物学基础

知识点 4：RL 与心理学/神经科学的联系

RL 不是凭空出现的，它在人类和动物身上也有对应：

理论	提出者	时间	核心内容
效果律 ⚖️	Thorndike	1911	带来好结果的行为会被强化，坏结果的会被削弱
条件反射 🔔	Pavlov	1927	狗听到铃声流口水 — 刺激和反应建立联系
操作条件反射 🐭	Skinner	1938	老鼠压杠杆得到食物 → 学会压杠杆
赫布理论 🔗	Hebb	1961	**Neurons that fire together, wire together.** 同时激活的神经元连接被强化
多巴胺奖励 💊	Carlsson	1957/2000 诺奖	多巴胺是大脑的"奖励信号"，和 RL 的 Reward 直接对应

> 💡 RL 不仅是计算机科学，也是理解动物和人类行为的重要理论框架。

三、📐 马尔可夫决策过程（MDP）（重点 ⭐）

知识点 5：MDP 的定义

MDP = Markov Decision Process，是 RL 问题的标准数学框架。

MDP 用五元组表示：⟨S, A, P, R, γ⟩

- **S** — 状态集合（所有可能的状态）
- **A** — 动作集合（所有可能的动作）
- **P** — 状态转移概率 P(s'|s, a)（做了动作 a 后到 s' 的概率）
- **R** — 奖励函数 R(s, a)（在 s 做 a 得到的即时奖励）
- **γ** — 折扣因子（0~1，未来的奖励折算到现在值多少）

知识点 6：马尔可夫性质（Markov Property）

核心定义：下一时刻的状态**只取决于当前状态和动作**，和之前的历史无关。

> P(s_{t+1} | s_t, a_t, s_{t-1}, a_{t-1}, ...) = P(s_{t+1} | s_t, a_t)

就像下棋 ♟️：你不需要知道之前怎么走到这一步的，只看**当前棋盘**就能决定下一步怎么走。

知识点 7：完全可观测 vs 部分可观测

类型	说明	例子
完全可观测（MDP） 👁️	Agent 能看到环境的全部状态	围棋（棋盘一目了然）
部分可观测（POMDP） 👓	Agent 只能看到部分状态	德州扑克（看不到对手的牌）

> 💡 **POMDP** = Partially Observable Markov Decision Process。这种情况下 Agent 需要记住历史信息来推断真实状态。

四、💰 奖励、回报和价值函数

知识点 8：Reward（奖励）vs Return（回报）

Reward（奖励） r_t：每一步的即时反馈 📨
Return（回报） G_t：从当前步开始到结束的**累计折扣奖励** 🧮

```
G_t = r_{t+1} + γ·r_{t+2} + γ²·r_{t+3} + ...
```

折扣因子 γ 的意义：

- γ → 0：只看眼前利益（短视 👀）

- γ → 1：有远见，未来的奖励也很重要（深谋远虑 🧐）
- 一般取值 0.9~0.99

知识点 9：Value Function（价值函数）—— 核心概念 ⭐

价值函数 = 预测未来能拿多少奖励 🔮

两种价值函数：

函数	符号	含义
状态价值函数 📊	V(s)	从状态 s 出发，按策略 π 行动，能拿到的期望回报
动作价值函数 🎯	Q(s, a)	在状态 s 做了动作 a，之后按策略 π 行动，能拿到的期望回报

公式：

```
V_π(s) = E[G_t | S_t = s]                    = E[r₁ + γ·r₂ + γ²·r₃ + ... | S_t = s]
Q_π(s, a) = E[G_t | S_t = s, A_t = a]        = E[r₁ + γ·r₂ + γ²·r₃ + ... | S_t = s, A_t = a]
```

> 💡 **V(s) 和 Q(s,a) 的关系**：Q(s,a) 比 V(s) 多指定了第一步的动作。知道了 Q(s,a)，选最大 Q 值的动作就是最优策略。

知识点 10：最优价值函数与最优策略

RL 的最终目标：找到**最优策略 π***，使得 V(s) 或 Q(s,a) 最大。

```
V*(s) = max_π V_π(s)      — 从状态 s 出发能得到的最大累计奖励
Q*(s,a) = max_π Q_π(s,a) — 在 s 做 a 能得到的最大累计奖励
```

确定最优策略：在每个状态 s，选 Q*(s,a) 最大的那个动作！

```
π*(s) = argmax_a Q*(s,a)
```

五、🚀 RL 发展里程碑

知识点 11：经典 RL 发展时间线

```
1950s  🧑‍🎓 Bellman → 动态规划、MDP 理论基础
1959   🧑‍🎓 Samuel → 跳棋程序（第一个 RL 应用 🎯）
1980s  📈 Barto & Sutton → 时序差分学习（TD Learning）
1989   📈 Watkins → Q-Learning 提出
1995   🚀 Tesauro → TD-Gammon 西洋双陆棋达到人类顶级水平
2013   💥 DeepMind → DQN 玩 Atari 游戏（深度强化学习诞生！）
2016   💥 DeepMind → AlphaGo 击败李世石 🏆
2017   💥 AlphaZero → 不用人类知识，从零自学围棋/象棋
2019   💥 OpenAI Five → 在 Dota 2 击败世界冠军 OG
2019   💥 AlphaStar → 星际争霸 II 达到大师级
2020   💥 OpenAI → 机械手还原魔方
```

知识点 12：深度强化学习的关键突破 — DQN

DQN（Deep Q-Network） = Q-Learning + 深度学习 🧠

为什么 DQN 是里程碑?

- 用**神经网络**代替 Q 表格，处理高维状态（如原始像素）
- 两个关键 trick：

Trick	作用
经验回放（Experience Replay） 🔄	存下过去的经验，随机抽样训练，打破数据相关性
目标网络（Target Network） 🎯	单独用一个网络算目标 Q 值，稳定训练

> 2013 年 DeepMind 用 DQN 在 Atari 2600 游戏上超越人类水平，是**深度强化学习**的开端 🚀

知识点 13：AlphaGo & AlphaZero

AlphaGo（2016）：

- 围棋状态空间 10^{170}，比宇宙原子总数还大 🌌
- 组合拳：**深度神经网络（策略网络+价值网络）+ 蒙特卡洛树搜索（MCTS）**
- 击败李世石（4:1），震动全球 🌍

AlphaZero（2017）：

- **完全从零自学**，不学人类棋谱，只靠自我对弈
- 同样的算法框架通吃围棋、象棋、将棋

知识点 14：OpenAI Five & 后续

项目	领域	规模
OpenAI Five 🎮	Dota 2（5v5 实时策略）	大规模分布式 RL
机械手还原魔方 🧩	机器人控制	Sim-to-Real 迁移
Emergent Tool Use 🛠️	多智能体	涌现使用工具的行为
Evolving RL Algorithms 🧬	AutoML	用进化算法自动发现新 RL 算法

六、🔑 RL 的核心要素 / 分类

知识点 15：RL 算法的三个核心要素

Agent 做决策需要三个关键组件：

```
┌──────────────────────────────────┐
│            RL Agent              │
│                                  │
│  ① Policy（策略） 📋              │
│     在状态 s 下，选择动作 a 的规则    │
│                                  │
│  ② Value Function（价值函数） 💰    │
│     评估当前状态/动作有多好          │
│                                  │
│  ③ Model（模型） 🌍               │
│     对环境的理解（选配）             │
└──────────────────────────────────┘
```

知识点 16：Model-based vs Model-free

类型	说明	优点/缺点
Model-based 🧠	Agent 试图"理解"环境，学习转移函数 P(s'|s,a) 和奖励函数 R(s,a)	✅ 更高效利用数据 ❌ 模型可能学错
Model-free 🎮	Agent 不学环境模型，直接学策略或价值函数	✅ 实现简单 ❌ 需要大量交互数据

知识点 17：Policy-based vs Value-based

类型	学什么	输出	适用场景
Value-based 📊	学价值函数 V(s) 或 Q(s,a)	从 Q 值选最大动作	离散动作空间
Policy-based 📋	直接学策略 π(a|s)	动作的概率分布	连续动作空间/随机策略
Actor-Critic 🎭	两者都学	Actor 做动作，Critic 评价	综合两者优势

📝 自测题

基础概念：

1. 强化学习和监督学习的最大区别是什么？
2. RL 的六个核心要素（Agent、Environment、State、Action、Reward、Policy）分别是什么？用你自己的例子解释。
3. 什么是马尔可夫性质（Markov Property）？

数学部分：

4. Return（回报）G_t 的定义是什么？折扣因子 γ 的作用是什么？
5. V(s) 和 Q(s, a) 分别代表什么？两者是什么关系？
6. Bellman Equation 的核心思想是什么？

算法分类：

7. Model-based 和 Model-free 的区别是什么？

8. Policy-based 和 Value-based 方法各有什么优缺点？
9. DQN 为什么需要"经验回放"和"目标网络"？

应用部分：
10. AlphaGo 为什么能击败人类围棋冠军？它用到了哪些技术？

📖 推荐资源

经典教材：

- Sutton & Barto, Reinforcement Learning: An Introduction（圣经级教材 📕）
- Szepesvári, Algorithms for Reinforcement Learning

重要论文：

- Mnih et al., Playing Atari with Deep Reinforcement Learning, 2013（DQN 开山之作）
- Mnih et al., Human-level control through deep reinforcement learning, Nature 2015
- Silver et al., Mastering the game of Go with deep neural networks and tree search, Nature 2016
- Silver et al., Mastering Chess and Shogi by Self-Play with a General RL Algorithm, 2017

视频课程：

- David Silver 的 RL 课程（B 站可看）